

유사문항 시스템 실현가능성 가이드



생각을 잇고 성장을 이룬다.
이음학원

매쓰아카이브 · 11만 문항 목표 전제 · 2026-04-19

핵심 결론 한 줄

매쓰플랫폼의 5~6단계 분류는 **그들 규모(100만)의 부산물**이지, 유사문항의 본질이 아님. 네 목표는 **얕은 계층 + 속성 벡터**. 지금 DB 버릴 필요 전혀 없음. 다만 **"진짜 되는지" 3일 실험(Stage 0)**을 먼저 해서 판단해야 함.

1. 네가 걱정한 3가지 — 그게 정확한 핵심 문제다

문제	증상	해법 (기술)
오라벨	인수분해라 했는데 사실 이차방정식	골드셋 + 정확도 측정 관문
일관성 없음	같은 패턴에 다른 라벨이 붙음	temperature=0 + Enum 강제 + 3회 앙상블
스키마 모호성	"핵심개념"의 정의 자체가 흐릿	속성별 값 후보를 사전에 확정 (자유텍스트 금지)

△ 왜 네가 느낀 산더미가 실제로 산더미인가

오라벨 5~25% × 11만 =

5,500~27,500개 오류

. 사람이 다 검수 불가능. 그래서 "라벨 자체를 덜 틀리게 하는 체계"를 먼저 만들어야 함.

2. 3가지 안전장치 (이거 없이 11만 시작하면 망함)

1 Temperature 0 + Seed 고정 → 재현성

같은 문제, 같은 프롬프트를 LLM에 두 번 돌려도 **매번 같은 답**이 나오도록 설정. 이것만으로도 일관성 문제 절반 해결.

2 Enum 강제 → 창의적 라벨 방지

"핵심개념"을 자유텍스트가 아니라 미리 만든 150~200개 개념 사전에서 선택하도록 강제. LLM이 "인수분해(고급)" 같은 이상한 라벨 못 만들. JSON Schema strict 모드로 구현.

3 양상블(3회 호출) → 자동 신뢰도

같은 문제에 3번 라벨링 → 3번 다 일치하면 신뢰, 아니면 "애매" 플래그 → 사람 검수 큐로. 네가 검수할 문항이 자동으로 필터링돼서 11만 개 아닌 몇 천 개로 줄어듬.

3. 단계별 실행 피라미드 — 관문식 진행

STAGE 0

50문항 실현가능성 실험 (3일)

Go/No-Go 결정 단계. 이거 안 하면 절대 다음 단계 가지 마.

STAGE 1

개념 사전 구축 (1~2주)

공수1~공수2 범위 핵심개념 150개 + 정의 직접 리스트업. LLM의 enum 값이 됨.

STAGE 2

1,028문항 PoC + 골드셋 (2~3주)

골드셋 300문항 + 전체 자동 라벨 + 오라벨율 <10% 목표 + Streamlit 유사검색 탭.

STAGE 3

중단원 하나 완주 (5,000문항)

프롬프트/스키마 개선, 배치 API 도입, 안정성 확인.

STAGE 4

11만 전체 확장

Stage 3 안정화 통과 후에만. 건너뛰면 재앙.

4. Stage 0 — 3일짜리 첫 실험 (제일 중요)

일자	할 일
Day 1	네가 잘 아는 단원(예: 인수분해) 50문항 선별 → 6~8개 속성을 네가 직접 엑셀에 수작업 라벨. 이게 골드셋.

일자	할 일
Day 2	Claude에 같은 프롬프트로 50문항 × 3회 라벨링 → 3번 답이 얼마나 일치하는지 (일관성), 네 골드셋과 얼마나 맞는지 (정확도) 측정.
Day 3	판단: · 일관성 >90% & 정확도 >85% → Go, Stage 1로 · 일관성 70~90% → 스키마 수정 후 재실험 · 일관성 <70% → 접고 다른 방향 (규칙기반, 수작업 보조 등)



Stage 0 비용

50문항 × 3회 = 150 API 호출 ≈

\$3~5

. 시간 투자 3일 (하루 2~3시간).

이걸로 "이 방향이 네 규모에서 되는지" 데이터로 판단 가능.

5. 네가 꼭 해야 할 수작업 — LLM이 절대 대체 못 함

1. 개념 사전 150개 만들기 (Stage 1, 10~20시간, 1회성) — 네 수학 전문성 핵심 자산
2. 골드셋 300~500문항 라벨 (Stage 2, 20~30시간)
3. LLM 출력 샘플 검수 (Stage 2~4, 꾸준히 5~10%)
4. 스키마 반복 수정 (Stage 0~2)
5. 임계값 튜닝 — "이 이상 유사하면 추천" 기준 결정

왜 이걸 외주 못 주냐

개발자는 파이프라인 구축은 잘하지만, "이 문제가 인수분해 맞나?"는

수학 교사만 판단 가능

. 즉 개발 파이프라인은 외주 줄 수 있어도

스키마 설계·골드셋 제작·검수는 네 몫

.

6. 파이프라인 개요 (기술 스택 미리보기)

```
HWPX 원본
  ↓ parse_hwp.py (이미 있음)
SQLite DB (questions 테이블, 이미 있음)
  ↓ scripts/label_questions.py (새로 만들 것)
Claude Batch API (temperature=0, JSON schema 강제)
  ↓ 3회 앙상블 + 합의 스코어
labels 테이블 (question_id → 12개 속성 벡터)
  ↓ scripts/embed_questions.py (새로 만들 것)
BGE-M3 문장 임베딩 + 태그 멀티핫 벡터 결합
  ↓ numpy pickle 또는 sqlite-vec
유사도 k-NN 검색 API
  ↓ app/main.py에 "유사문항 top-5" 탭 추가
Streamlit UI (이미 있음)
```

7. 최종 결정 — 지금 네가 고를 것

옵션	내용	추천도
A	Stage 0 (3일 실험) 지금 시작 → 데이터로 판단	★★★ 최우선 추천
B	시험지/교재 운영에 집중 + 기출 적재 확대. 유사문항은 나중에	★★ 안정형
C	그 강사와 협업 가능성 타진 → 11만 라벨링 안 해도 결과 공유	★★ 관계가 된다면

✓ 내 추천

옵션 A. 3일 투자로 "네 규모에서 진짜 되는지" 데이터로 검증 → 이후 나머지 결정. Stage 0 돌려보고
실제 결과 숫자 손에 쥐고
판단하면 산더미 느낌 사라짐.

8. 보너스 — "동업자 / 외주" 질문 답

동업자?

이상적 배분: 너=수학 도메인·사업·교재 품질, 동업자=ML/백엔드 개발. 개발 파트너 있으면 Stage 1~4 속도 2~3배. 단 도메인 수작업(개념 사전·검수)은 네가 계속 해야 함.

주의: 공동창업 동업자는 지분 문제가 관계 파탄 위험. 초반엔 프리랜서/파트타임 개발 협업부터 타진하고, 잘 맞으면 그 후에 동업 얘기.

외주 비용?

범위	현실적 비용 (한국)	비고
파이프라인 개발만 (라벨링/임베딩/검색 API)	500만~1,500만원	프리랜서 2~3개월
+ Streamlit UI 개선 + 운영 자동화	1,500만~3,000만원	중견 개발자 3~4개월
+ 11만 문항 라벨링 대행까지	5,000만~1억+	인건비 대부분, 데이터 품질 보장 어려움
매쓰플랫폼 수준 복제 시도	5억~수십억 / 수년	비현실적 — 매쓰플랫폼은 수십 명 × 9년

△ 외주 합정

- **라벨 품질은 결국 네가 검수**
해야 하는데, 외주로 맡기면 검수 루프가 끊김
- **스키마 정의 없이 외주 맡기면**
개발자가 대충 만들고 넘기고 네가 고생
- 외주는
파이프라인(코드) 구축
까지만 맡기고,
라벨링 운영은 네가 직접
권장

현실적 조합

1. **Stage 0~2는 나(Claude Code)와 함께** — 비용 거의 0, 네 통제
2. Stage 2 통과하면 **Stage 3 파이프라인 개발만 외주** (500만~1,500만원) 또는 동업자에게 위탁
3. 라벨 품질/스키마/검수는 **끝까지 네 몫** — 외주도 동업자도 대체 불가